

ANALITIK DAN VISUALISASI DATA
“PATIENT SEGMENTATION”



Disusun oleh:

Dzulrrahim Oscar Aditya Akbar (2509116107)

Program Studi Sistem Informasi
Fakultas Teknik
Universitas Mulawarman
2026

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya penulis dapat menyelesaikan laporan yang berjudul “Analisis Patient Segmentation dan Faktor Kesehatan Pasien” dengan baik dan tepat waktu. Laporan ini disusun sebagai bagian dari kegiatan analisis data untuk memahami berbagai faktor yang berkaitan dengan kondisi kesehatan pasien melalui proses eksplorasi data, pengolahan data, serta pembuatan visualisasi dashboard dan tugas Ujian Tengah Semester (UTS) dari bapak .Dr. Akhmad Irsyad, S.T., M.Kom.

Dalam penyusunan laporan ini, penulis melakukan analisis terhadap beberapa variabel yang terdapat dalam dataset, seperti usia pasien, indeks massa tubuh (BMI), jumlah kunjungan tahunan, kondisi penyakit utama (Primary Condition), jumlah penyakit kronis, serta jenis asuransi kesehatan yang dimiliki pasien. Analisis tersebut bertujuan untuk mengidentifikasi pola, tren, serta hubungan antar variabel yang dapat memberikan gambaran mengenai kondisi kesehatan pasien dan tingkat pemanfaatan layanan kesehatan.

Hasil dari analisis data kemudian disajikan dalam bentuk visualisasi dashboard sehingga informasi yang diperoleh dapat lebih mudah dipahami. Melalui visualisasi tersebut, diharapkan dapat terlihat pola tertentu, seperti distribusi penyakit yang paling sering terjadi, frekuensi kunjungan pasien, serta faktor-faktor yang berpotensi memengaruhi kondisi kesehatan pasien.

Penulis menyadari bahwa dalam penyusunan laporan ini masih terdapat berbagai kekurangan, baik dari segi penyajian maupun isi laporan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun dari berbagai pihak agar laporan ini dapat menjadi lebih baik di masa yang akan datang.

Akhir kata, penulis berharap laporan ini dapat memberikan manfaat serta menambah wawasan bagi pembaca, khususnya dalam memahami pemanfaatan analisis data dan visualisasi dashboard dalam bidang kesehatan guna mendukung pengambilan keputusan yang lebih efektif.

Samarinda, .. Maret 2026

Dzulrrahim Oscar Aditya Akbar

DAFTAR ISI

KATA PENGANTAR.....	1
DAFTAR ISI.....	2
DAFTAR GAMBAR.....	3
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Tujuan Analisis.....	4
BAB II PEMBAHASAN.....	5
2.1 Business Understanding.....	5
2.2 Data Understanding & EDA.....	6
2.3 Data Preparation.....	16
BAB III PENUTUP.....	19
3.1 Kesimpulan.....	19
3.2 Saran.....	19

DAFTAR GAMBAR

Gambar 1 Informasi Statistik Deskriptif.....	8
Gambar 2 Mengecek Tipe Data.....	11
Gambar 3 Mengecek Missing Values.....	11
Gambar 4 Comparison.....	13
Gambar 5 Composition.....	14
Gambar 6 Distribution.....	15
Gambar 7 Relationship.....	16

BAB I

PENDAHULUAN

1.1 Latar Belakang

Data pada layanan kesehatan seperti kondisi pasien, jumlah kunjungan, dan biaya perawatan dapat digunakan untuk membantu pengambilan keputusan. Namun, data tersebut sering kali hanya disimpan tanpa dianalisis lebih lanjut, sehingga informasi penting di dalamnya tidak dimanfaatkan secara optimal.

Dalam data pasien, setiap kondisi kesehatan memiliki karakteristik yang berbeda. Ada kondisi dengan jumlah pasien tinggi, ada yang memiliki frekuensi kunjungan tinggi, dan ada juga yang memiliki biaya perawatan lebih besar. Karena itu, diperlukan analisis data untuk memahami pola tersebut agar pengelolaan layanan kesehatan menjadi lebih efektif.

Salah satu pendekatan yang digunakan adalah segmentasi pasien, yaitu pengelompokan pasien berdasarkan karakteristik tertentu seperti Primary Condition, Annual Visits, Billing Amount, dan Last Visit Date. Analisis ini membantu melihat kondisi yang paling dominan, pola kunjungan pasien, serta perbedaan beban biaya perawatan.

Untuk mempermudah pemahaman, data divisualisasikan dalam bentuk dashboard. Dashboard menampilkan distribusi kondisi pasien, tren kunjungan, dan perbandingan rata-rata biaya perawatan. Dengan demikian, analisis data pasien dan dashboard dapat mendukung proses business understanding serta membantu pengambilan keputusan dalam pengelolaan layanan kesehatan.

1.2 Tujuan Analisis

1. Memahami pola dan karakteristik data pasien berdasarkan variabel yang ada.
2. Mengetahui kondisi pasien yang paling dominan
3. Mengetahui pola kunjungan pasien
4. Mengetahui perbedaan rata-rata biaya perawatan pada setiap kondisi kesehatan.

BAB II

PEMBAHASAN

2.1 Business Understanding

Penyedia layanan kesehatan menghadapi tantangan dalam memberikan perawatan yang dipersonalisasi dan melakukan pemasaran kepada beragam populasi pasien. Pendekatan *one-size-fits-all* (satu solusi untuk semua) terbukti gagal karena menyebabkan pasien tidak patuh pada program pencegahan dan sumber daya terbuang sia-sia.

1. Business Objective

Menggunakan data untuk melakukan Segmentasi Pasien guna menciptakan strategi pemasaran dan layanan kesehatan yang spesifik untuk setiap kelompok, sehingga meningkatkan kepuasan pasien dan efisiensi biaya. Secara spesifiknya;

- a. Membuat Segmentasi = Memecah 2.000 pasien menjadi 3-5 kelompok yang punya sifat mirip.
- b. Personalisasi Layanan = Memberikan apa yang benar benar dibutuhkan tiap kelompok. seperti untuk orang sehat diajak untuk hidup lebih sehat (gym/suplemen/vitamin), untuk orang sakit diingatkan untuk meminum obat dan melakukan kontrol.
- c. Personalisasi Layanan = Memberikan apa yang benar benar dibutuhkan tiap kelompok. seperti untuk orang sehat diajak untuk hidup lebih sehat (gym/suplemen/vitamin), untuk orang sakit diingatkan untuk meminum obat dan melakukan kontrol.

2. Assess Situation

Organisasi memiliki aset data yang komprehensif, mencakup dimensi demografi (usia, lokasi), klinis (BMI, kondisi kronis), finansial (asuransi, tagihan), dan perilaku (kunjungan terakhir). Data ini dinilai sangat memadai untuk melakukan analisis pola mendalam. Meskipun terdapat beberapa data lokasi yang tidak lengkap, variabel kunci lainnya sudah cukup kuat untuk membentuk dasar pemodelan segmentasi yang akurat.

3. Analytic Goals

Untuk mendukung strategi pemasaran dan manajemen perawatan yang tepat sasaran, tim analitik akan berfokus pada pengolahan data klinis dan perilaku guna

mengeksktraksi wawasan terkait risiko kesehatan serta potensi loyalitas pasien melalui target-target berikut:

- a. Identifikasi Risiko dan Intervensi: Memetakan pasien berisiko tinggi (kondisi kronis/obesitas) yang jarang berkunjung untuk memicu intervensi dini melalui layanan seperti telemedicine.
- b. Analisis Nilai Jangka Panjang: Mengukur potensi segmen pasien muda dan sehat untuk dirancang strategi retensinya melalui layanan pencegahan dan gaya hidup.
- c. Optimasi Layanan Prioritas: Menganalisis kebutuhan pasien lansia dan pengguna asuransi rutin guna menyelaraskan fasilitas fisik dan kenyamanan operasional yang meningkatkan loyalitas.

2.2 Data Understanding & EDA

Bagian ini dilakukan terlebih dahulu pemahaman terhadap dataset yang digunakan sebelum melakukan analisis lebih lanjut. Tujuan dari Data Understanding ini adalah untuk mengetahui struktur data, tipe data, kelengkapan data, serta mendeteksi potensi permasalahan pada dataset seperti missing values, duplikasi data, dan outlier.

Dataset ini berisi informasi terkait profil pasien, kondisi kesehatan, dan perilaku kunjungan pasien ke layanan kesehatan. Dataset ini digunakan untuk memahami karakteristik pasien dan melakukan analisis lebih lanjut terhadap pola kesehatan pasien. Dataset ini memiliki beberapa atribut mengenai hal tersebut seperti;

- PatientID : ID pasien
- Age : Usia pasien
- Gender : Jenis kelamin pasien
- State dan City : Tempat tinggal atau asal pasien
- BMI : Indeks masa tubuh pasien
- Insurance_Type : tipe asuransi pasien
- Primary_Condition : Kondisi utama kesehatan pasien
- Num_Chronic_Conditions : Jumlah penyakit kronis pasien
- Annual_Visits : Jumlah kunjungan pasien per tahun
- Avg_Billing_Amount : Rata-rata biaya yang dikeluarkan pasien
- Last_Visit_Date : Tanggal kunjungan terakhir pasien
- Days_Since_Last_Visit : Jumlah hari sejak kunjungan terakhir

- Preventive_Care_Flag : Indikator layanan pencegahan

Import Library

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

Pada bagian ini dilakukan *import library* yang dibutuhkan, adapun *library* yang di-import adalah pandas yang digunakan untuk membaca dan memproses dataset dalam bentuk tabel, seaborn digunakan untuk membuat visualisasi data yang lebih informatif, dan matplotlib digunakan untuk membuat grafik atau plot data.

Menghubungkan Google Drive

```
from google.colab import drive
drive.mount('/content/drive')
```

Pada bagian ini dilakukan penghubungan *Google Colab* dengan *Google Drive* sehingga file dataset yang tersimpan di *Google Drive* dapat diakses langsung pada lingkungan *Google Colab*.

Membaca Dataset

```
path = "/content/drive/MyDrive/AVD Dataset/patient_segmentation_dataset.csv" df =
pd.read_csv(path)

df
df.info()
```

Pada bagian dilakukan deklarasi variable path yang menyimpan value berupa path atau jalur direktori ke file dataset yang akan digunakan. Setelahnya mendeklarasikan variable df sebagai pd.read_csv(path) yang dimana ini merupakan kode untuk membaca file dataset yang berformat CSV. Perintah df dijalankan untuk menampilkan isi dataset dan df.info() untuk melihat struktur dari dataset, struktur dataset sendiri yaitu jumlah baris data, jumlah kolom, tipe data setiap kolom, dan jumlah data yang tidak kosong.

Informasi Statistik Deskriptif

```
df.describe(include='all')
```



```
df.describe(include='all')
```

	PatientID	Age	Gender	State	City	Height_cm	Weight_kg	BMI	Insurance_Type	Primary_Condition	Num_Chronic_Conditions	Annual_Visits	Avg_Billing
count	2000	2000.00000	2000	2000	2000	2000.000000	2000.000000	2000.000000	2000	1505	2000.000000	2000.000000	200
unique	2000	NaN	2	10	20	NaN	NaN	NaN	4	9	NaN	NaN	
top	P11983	NaN	Female	NC	Unknown	NaN	NaN	NaN	Medicare	Hypertension	NaN	NaN	
freq	1	NaN	1001	213	1012	NaN	NaN	NaN	906	210	NaN	NaN	
mean	NaN	50.69550	NaN	NaN	NaN	167.907500	85.143500	30.740650	NaN	NaN	1.080000	5.466500	400
std	NaN	15.44445	NaN	NaN	NaN	12.684494	20.385428	8.839952	NaN	NaN	0.890504	3.485965	246
min	NaN	18.00000	NaN	NaN	NaN	145.000000	50.000000	13.400000	NaN	NaN	0.000000	1.000000	20
25%	NaN	40.00000	NaN	NaN	NaN	158.000000	67.000000	23.800000	NaN	NaN	1.000000	3.000000	206
50%	NaN	51.00000	NaN	NaN	NaN	168.000000	86.000000	30.100000	NaN	NaN	1.000000	4.000000	370
75%	NaN	63.25000	NaN	NaN	NaN	177.000000	103.000000	37.025000	NaN	NaN	1.000000	8.000000	565
max	NaN	87.00000	NaN	NaN	NaN	195.000000	120.000000	57.100000	NaN	NaN	3.000000	12.000000	1246

Gambar 1 Informasi Statistik Deskriptif

Pada bagian ini, ditampilkan statistik deskriptif dari dataset seperti count, mean, std, min dan max, quartile.

1. Count (Kelengkapan Data) Berdasarkan data, total baris transaksi adalah 2000. Maka dapat disimpulkan:

- Primary_Condition hilang 495 data (2000 - 1505)

Kesimpulan: Kolom Primary_Condition mengandung missing values, sementara kolom lainnya sudah lengkap (2000 data)

2. Mean vs Median (Distribusi Data)

- Kolom Age
 - Mean = 50.695
 - Median = 51.00
- Kolom Height_cm
 - Mean = 167.907
 - Median = 168.00
- Kolom Weight_kg
 - Mean = 85.143
 - Median = 86.00
- Kolom BMI
 - Mean = 30.740
 - Median = 30.10
- Kolom Num_Chronic_Condition
 - Mean = 1.080
 - Median = 1.00
- Kolom Annual_Visits

- Mean = 5.466
 - Median = 4.00
- Kolom Average_Billing_Amount
 - Mean = 4000.270
 - Median = 3707.25
- Kolom Days_Since_Last_Visit
 - Mean = 180.085
 - Median = 183.00
- Kolom Preventive_Care_Flag
 - Mean = 0.464
 - Median = 0.00


3. Min dan Max (Validasi Logika)

- Kolom Age
 - Min = 18
 - Max = 87
- Kolom Height_cm
 - Min = 145
 - Max = 195
- Kolom Weight_kg
 - Min = 50
 - Max = 120
- Kolom BMI
 - Min = 13
 - Max = 57
- Kolom Num_Chronic_Condition
 - Min = 0
 - Max = 3
- Kolom Annual_Visits
 - Min = 1
 - Max = 12
- Kolom Average_Billing_Amount
 - Min = 207
 - Max = 12467

- Kolom Days_Since_Last_Visit
 - Min = 1
 - Max = 365
- Kolom Preventive_Care_Flag
 - Min = 0
 - Max = 1
- 4. Standar Deviasi (std) - Variabilitas Data
 - Kolom Age
 - Mean = 50.695
 - Std = 15.444
 - Kolom Height_cm
 - Mean = 167.907
 - Std = 12.684
 - Kolom Weight_kg
 - Mean = 85.143
 - Std = 20.385
 - Kolom BMI
 - Mean = 30.740
 - Std = 8.839
 - Kolom Num_Chronic_Condition
 - Mean = 1.080
 - Std = 0.890
 - Kolom Annual_Visits
 - Mean = 5.466
 - Std = 3.485
 - Kolom Average_Billing_Amount
 - Mean = 4000.270
 - Std = 2463.2392
 - Kolom Days_Since_Last_Visit
 - Mean = 180.085
 - Std = 104.688
 - Kolom Preventive_Care_Flag
 - Mean = 0.464
 - Std = 0.498

Mengecek Tipe Data

df.dtypes



PatientID	object
Age	int64
Gender	object
State	object
City	object
Height_cm	int64
Weight_kg	int64
BMI	float64
Insurance_Type	object
Primary_Condition	object
Num_Chronic_Conditions	int64
Annual_Visits	int64
Avg_Billing_Amount	float64
Last_Visit_Date	object
Days_Since_Last_Visit	int64
Preventive_Care_Flag	int64


dtype: object

Gambar 2 Mengecek Tipe Data

Pada bagian ini melakukan pengecekan tipe data dengan melakukan kode di atas untuk mengetahui tipe data dari setiap kolom.

Pengecekan Missing Values

pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])



	Null Ratio in %
PatientID	0.00
Age	0.00
Gender	0.00
State	0.00
City	0.00
Height_cm	0.00
Weight_kg	0.00
BMI	0.00
Insurance_Type	0.00
Primary_Condition	24.75
Num_Chronic_Conditions	0.00
Annual_Visits	0.00
Avg_Billing_Amount	0.00
Last_Visit_Date	0.00
Days_Since_Last_Visit	0.00
Preventive_Care_Flag	0.00

Gambar 3 Mengecek Missing Values

Pada bagian ini melakukan pengecekan data dengan perintah tersebut untuk mengecek apakah terdapat data yang hilang pada setiap kolom.

Mengecek Duplicate Values

```
df[df.duplicated()]
```

Pada bagian ini dilakukan perintah tersebut untuk melakukan pengecekan apakah terdapat data yang sama atau duplikat dalam dataset.

Mengecek Outlier

```
results = []

cols = df.select_dtypes(include=['float64', 'int64'])


for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)

display(results_df)
```

Pada bagian ini dilakukan pengecekan apakah terdapat outlier pada dataset dan untuk mengeceknya menggunakan metode IQR (Interquartile Range).

Comparison




Gambar 4 Comparison

Pada bagian ini, Membandingkan kunjungan tahunan (Annual_Visits) dengan kondisi awal pasien (Primary_Condition). Tujuannya untuk mengidentifikasi berapa banyak jumlah kunjungan tahunan pasien sesuai dengan penyakit yang diderita. Visualisasi yang digunakan adalah Bar Chart (Grafik Batang)

Composition


Proporsi 3 Kategori Kunjungan Teratas Berdasarkan Usia
51



Gambar 5 Composition

Pada bagian ini, melihat proporsi atau persentase total kunjungna tahunan (Annual_Visits) berdasarkan usia pasien (Age). Tujuannya untuk mengetahui usia mana yang mendominasi kunjungan dalam kunjungan tahunan mereka. Visualisas yang digunakan adalah Pie Chart (Grafik Lingkaran).


Distribution



Gambar 6 Distribution

Pada bagian ini, menganalisis penyebaran nilai kunjungan pada kolom Annual_Visits. Tujuannya melihat apakah mayoritas kunjungan tahunan bernilai kecil atau besar, serta mendeteksi adanya kecondongan (skewness) dalam data kunjungan. Visualisasi yang digunakan adalah Histogram.

Relationship



Gambar 7 Relationship

Pada bagian ini, menganalisis korelasi antara kunjungan tahunan (Annual_Visits) dengan jumlah hari setelah kunjungan terakhir (Days_Since_Last_Visit).

Tujuannya untuk mengetahui apakah peningkatan kunjungan tahunan selalu berbanding lurus dengan rentang waktu kunjungan mereka dengan melihat jumlah hari setelah kunjungan terakhir pasien, serta mengidentifikasi kunjungan yang memiliki kunjungan dengan frekuensi tinggi (sering). Visualisasi yang digunakan adalah Heatmap

2.3 Data Preparation

Pada tahap ini, dilakukan proses pembersihan, penanganan, dan persiapan dataset sebelum dilakukan analisis lebih lanjut. Tahapan ini bertujuan untuk memastikan bahwa data yang digunakan memiliki kualitas yang baik, konsisten, serta bebas dari kesalahan yang dapat mempengaruhi hasil analisis. Untuk penanganannya dilakukan beberapa proses seperti penanganan inconsisten values, penanganan missing values, dan penanganan outlier.

Penanganan Tipe Data

```
df["Last_Visit_Date"] = pd.to_datetime(df["Last_Visit_Date"], format="mixed")
```

Pada bagian ini dilakukan pengubahan data yang tidak sesuai yaitu kolom Last_Visit_Date yang bertipe data object yang seharusnya bertipe data datetime.

Penanganan Missing Values

```
print((df.isna().sum() / len(df)) * 100)

df['Primary_Condition'] = df['Primary_Condition'].fillna(df['Primary_Condition'].dropna().mode()[0])
```

Pada tahap ini, dilakukan penanganan untuk missing values. Untuk missing values sendiri jika di atas 70% akan dihapus dan di bawah 70% akan diimputasi. Pertama-tama dilakukan terlebih dahulu perintah pertama untuk mengecek persentase missing values, karena missing values berada di bawah 70% maka dilakukan imputasi dengan menggunakan perintah kedua.

Penanganan Outliers

```
results = []

cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
```

```

results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)

columns_to_impute = ["Num_Chronic_Conditions", "Avg_Billing_Amount", "BMI"]

for col in columns_to_impute:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

# Menggunakan .loc[] agar tidak muncul SettingWithCopyWarning
df.loc[:, col] = df[col].clip(lower=lower_bound, upper=upper_bound)

```

Pada bagian ini, dilakukan penanganan outliers. Pertama-tama lakukan perintah pertama untuk mengecek persentase outliers, dikarenakan outliers sebanyak 46% yang dimana ini di bawah 70% maka dilakukan imputasi dengan menjalankan perintah kedua.

BAB III

PENUTUP

3.1 Kesimpulan

Dari hasil visualisasi diketahui bahwa Hypertension merupakan kondisi yang paling dominan dengan jumlah kunjungan pasien tertinggi dibandingkan kondisi lainnya. Selain itu, tren kunjungan pasien sepanjang tahun menunjukkan pola yang fluktuatif dengan beberapa bulan mengalami peningkatan jumlah kunjungan.

Analisis rata-rata biaya perawatan menunjukkan bahwa sebagian besar kondisi memiliki biaya yang relatif mirip, namun Diabetes memiliki rata-rata biaya perawatan yang lebih tinggi dibandingkan kondisi lainnya. Hal ini menunjukkan bahwa jumlah kunjungan pasien tidak selalu berbanding lurus dengan biaya perawatan yang dikeluarkan.

3.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan analisis selanjutnya.

Pertama, pada penelitian selanjutnya dapat dilakukan analisis yang lebih mendalam dengan menggunakan metode data mining atau machine learning, seperti clustering, untuk melakukan segmentasi pasien secara lebih akurat.

Kedua, dataset yang digunakan dapat dikembangkan dengan menambahkan variabel lain yang lebih lengkap, seperti riwayat penyakit pasien, jenis perawatan yang diterima, atau lama perawatan, sehingga analisis yang dihasilkan dapat menjadi lebih komprehensif.